Fairness & Bias Audit

LightGBM + WOE

Evaluación principal: OOT

Threshold evaluado: 0.8200

Variables auditadas:

customer_age | income | employment_status

El reporte evalúa disparidad de resultados y posibles efectos proxy.

El threshold actual es provisional hasta completar la selección operacional.

Resumen ejecutivo de Fairness

LightGBM + WOE | OOT | Threshold = 0.8200

variable	demographic_parity_diff	disparate_impact_ratio	equal_opportunity_diff	fpr_gap	equalized_odds_gap
customer_age	9.26%	0.1834	29.39%	6.66%	29.39%
income	5.34%	0.3005	15.35%	4.67%	15.35%
employment_status	12.94%	0.0169	55.95%	10.89%	55.95%

Interpretación:
- Demographic Parity Difference mide diferencias en la tasa de selección entre grupos.
- Equal Opportunity Difference mide diferencias en TPR o capacidad de detectar fraude real.
- FPR Gap mide diferencias en falsos positivos entre grupos.
- Equalized Odds considera conjuntamente las diferencias en TPR y FPR.
- Disparate Impact Ratio se utiliza como indicador descriptivo y no como criterio único de fairness.

Estabilidad temporal del Fairness

Comparación Test vs OOT

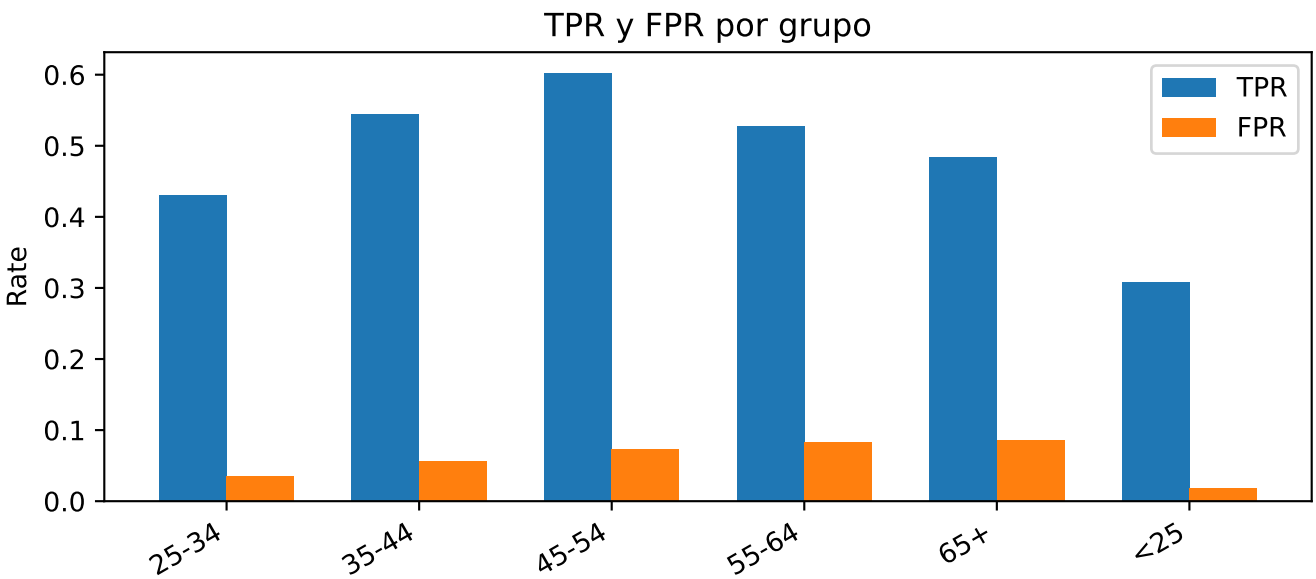
dataset	variable	demographic_parity_diff	disparate_impact_ratio	equal_opportunity_diff	fpr_gap	equalized_odds_gap
OOT	customer_age	9.26%	0.1834	29.39%	6.66%	29.39%
Test	customer_age	8.20%	0.2329	30.86%	6.68%	30.86%
OOT	employment_status	12.94%	0.0169	55.95%	10.89%	55.95%
Test	employment_status	8.76%	0.0161	55.08%	7.44%	55.08%
OOT	income	5.34%	0.3005	15.35%	4.67%	15.35%
Test	income	6.24%	0.2952	23.53%	5.52%	23.53%

Interpretación:
- La comparación temporal permite identificar si las disparidades persisten fuera del periodo de evaluación inicial.
- Una disparidad presente tanto en Test como en OOT representa una señal más consistente que una diferencia aislada.

Fairness - customer_age

LightGBM + WOE | OOT | Threshold = 0.8200

group	n	fraud_count	base_rate	selection_rate	precision	TPR	FPR
25-34	32,363	405	1.25%	4.00%	13.43%	42.96%	3.51%
35-44	27,860	436	1.56%	6.32%	13.45%	54.36%	5.56%
45-54	9,725	256	2.63%	8.67%	18.27%	60.16%	7.28%
55-64	2,501	131	5.24%	10.64%	25.94%	52.67%	8.31%
65+	441	31	7.03%	11.34%	30.00%	48.39%	8.54%
<25	23,953	169	0.71%	2.08%	10.44%	30.77%	1.88%

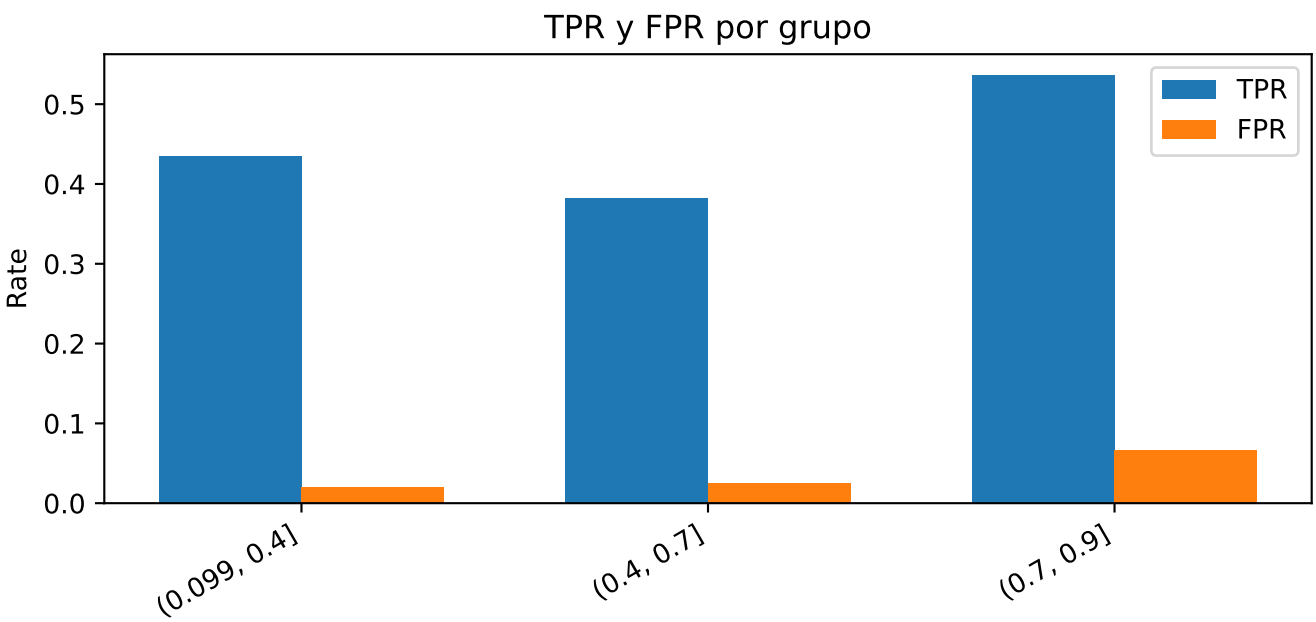


Demographic Parity Difference: 9.26%
Disparate Impact Ratio: 0.1834
Equal Opportunity Difference: 29.39%
FPR Gap: 6.66%
Equalized Odds Gap: 29.39%

Fairness - income

LightGBM + WOE | OOT | Threshold = 0.8200

group	n	fraud_count	base_rate	selection_rate	precision	TPR	FPR
(0.099, 0.4]	27,617	221	0.80%	2.30%	15.14%	43.44%	1.96%
(0.4, 0.7]	25,606	272	1.06%	2.93%	13.89%	38.24%	2.55%
(0.7, 0.9]	43,620	935	2.14%	7.64%	15.04%	53.58%	6.63%

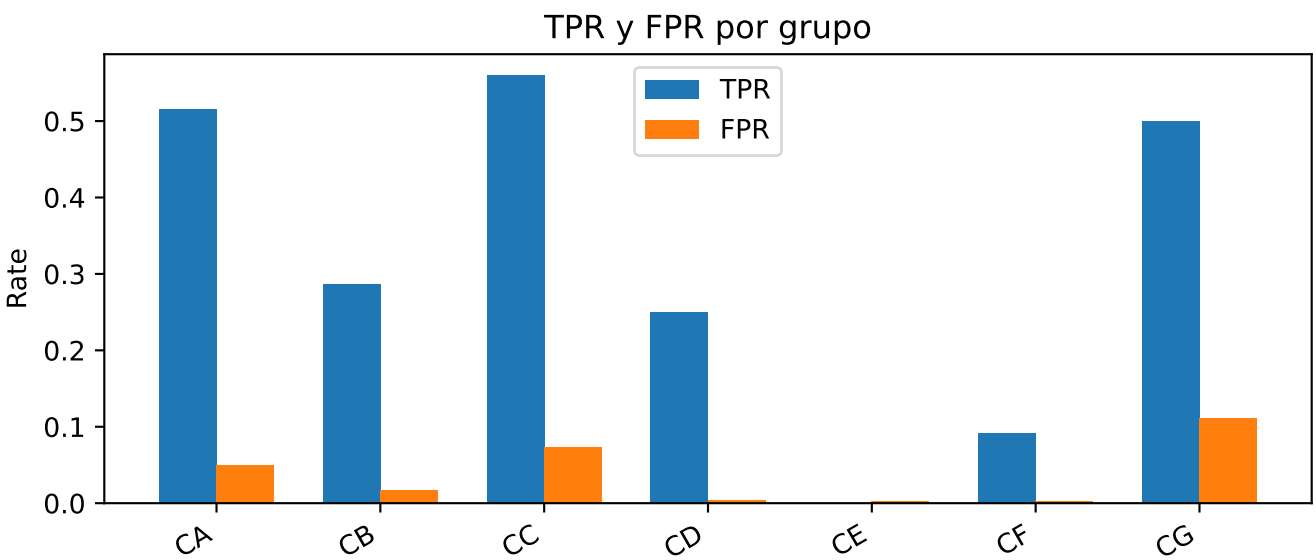


Demographic Parity Difference: 5.34%
Disparate Impact Ratio: 0.3005
Equal Opportunity Difference: 15.35%
FPR Gap: 4.67%
Equalized Odds Gap: 15.35%

Fairness - employment_status

LightGBM + WOE | OOT | Threshold = 0.8200

group	n	fraud_count	base_rate	selection_rate	precision	TPR	FPR
CA	74,882	1,195	1.60%	5.67%	14.50%	51.55%	4.93%
CB	11,275	115	1.02%	2.02%	14.47%	28.70%	1.75%
CC	2,265	84	3.71%	9.14%	22.71%	55.95%	7.34%
CD	2,513	12	0.48%	0.48%	25.00%	25.00%	0.36%
CE	2,252	9	0.40%	0.22%	0.00%	0.00%	0.22%
CF	3,618	11	0.30%	0.30%	9.09%	9.09%	0.28%
CG	38	2	5.26%	13.16%	20.00%	50.00%	11.11%



Demographic Parity Difference: 12.94%
Disparate Impact Ratio: 0.0169
Equal Opportunity Difference: 55.95%
FPR Gap: 10.89%
Equalized Odds Gap: 55.95%

Proxy Audit - Asociación con el score

LightGBM + WOE | OOT

variable	metric	value
proposed_credit_limit	spearman_score	0.2277
credit_limit_income_ratio	spearman_score	0.0165

Interpretación:
- La correlación con el score no demuestra por sí sola que una variable sea un proxy problemático.
- Valores altos en magnitud indican que la variable merece una revisión adicional.

Proxy Audit - Asociación con variables sensibles

LightGBM + WOE | OOT

proxy	sensitive_variable	spearman_corr
credit_limit_income_ratio	income	-0.5964
proposed_credit_limit	customer_age	0.1350
proposed_credit_limit	income	0.1200
credit_limit_income_ratio	customer_age	-0.0121

Interpretación:
- Esta sección analiza si variables utilizadas por el modelo están asociadas con características monitoreadas por fairness.
- credit_limit_income_ratio incorpora income por construcción, por lo que su asociación debe interpretarse teniendo en cuenta esta relación directa.
- La asociación estadística debe complementarse con el análisis de disparidad de resultados.

Conclusiones y próximos pasos

1. La auditoría principal se realiza sobre OOT para evaluar el comportamiento del modelo en un periodo futuro.

2. customer_age se mantiene fuera del modelo y se utiliza exclusivamente para monitoreo de fairness.

3. income y employment_status permanecen en el modelo, pero requieren seguimiento explícito de disparidad.

4. Las diferencias de TPR y FPR son especialmente relevantes porque indican si determinados grupos reciben distinto nivel de protección o fricción.

5. El proxy analysis identifica asociaciones que deben investigarse, pero una correlación no implica por sí sola discriminación.

6. Los resultados deberán revisarse nuevamente cuando se defina el threshold operacional definitivo.

Siguiente etapa: revisar posibles medidas de mitigación y posteriormente realizar análisis de explicabilidad con SHAP.